GreenScope • Labs

GREENSCOPE · DOCUMENTACIÓN

ML y CRISP-ML(Q)

Modelos, series temporales, métricas y gestión de calidad

Versión 0.2
Fecha 25 de octubre de 2026
Autoría GreenScope Labs · proyecto independiente
Estado Documento iterativo · experimento personal

Contenido

1 Marco metodológico: CRISP-ML(Q) 2
2 Fase a fase aplicada a GreenScope 3
3 Datos y features 4
4 Modelado 5
4.1 Segmentación de vegetación 5
4.2 Series temporales 5
4.3 Modelo de déficit 5
4.4 Ranking multicriterio de propuestas 5
5 Métricas y resultados 7
6 Gestión de calidad, monitorización y active learning 8

1 Marco metodológico: CRISP-ML(Q)

CRISP-ML(Q) extiende CRISP-DM con una **fase de monitorización y mantenimiento** y con la **gestión de calidad (Q)** en cada fase: riesgos, métricas de aceptación y criterios de parada. Es el marco apropiado para un sistema que se opera en el tiempo y cuyos datos derivan.

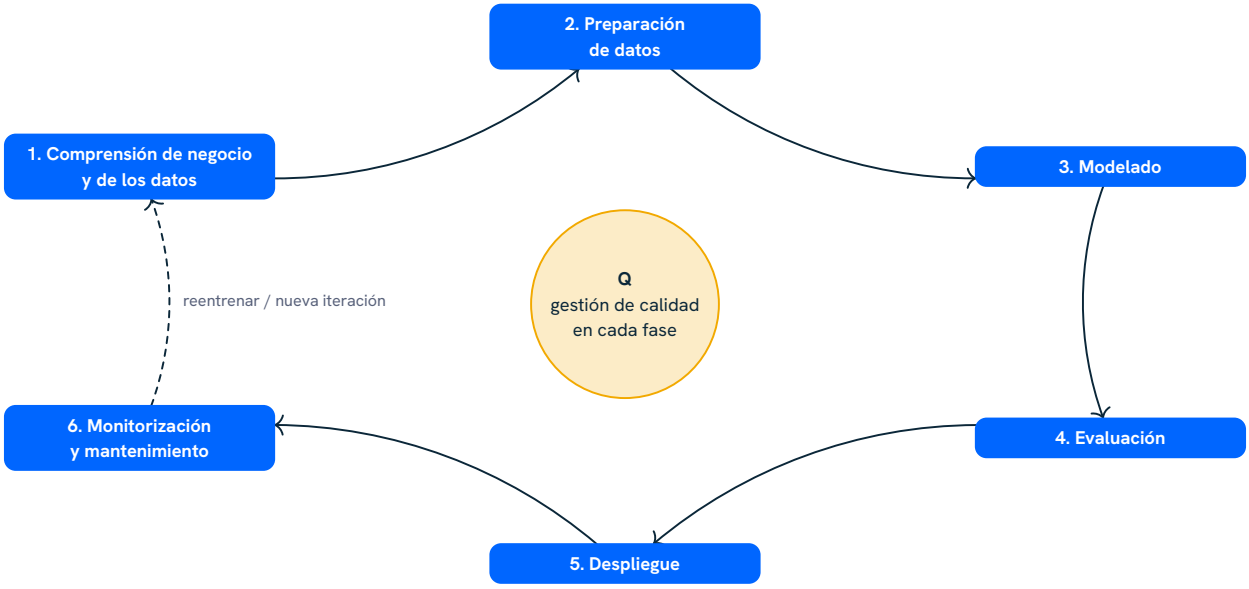


Figura 1: Ciclo de las seis fases de CRISP-ML(Q) con gestión de calidad transversal.

2 Fase a fase aplicada a GreenScope

Fase	Actividades en el caso	Gestión de calidad (Q)
1. Negocio y datos	Objetivo: priorizar dónde actuar y qué parcelas proponer. Éxito: el técnico aprueba o ajusta una proporción alta de propuestas y reduce el tiempo de análisis. Inventario de fuentes y su licencia.	Riesgo: datos sintéticos tomados por reales; sesgo de OSM. Criterio: etiquetado de origen en cada fuente.
2. Preparación	Proyección a malla H3 res. 9; features por celda; tratamiento de huecos por nubes; escalado a [0,1].	Validación de esquema, rangos y completitud; pruebas con semilla fija.
3. Modelado	Segmentación de vegetación, series temporales, modelo de déficit, ranking de propuestas (secciones siguientes).	Comparar con un baseline simple; registrar versión de modelo.
4. Evaluación	AUC, F1 en el umbral crítico, MAE de previsión, estabilidad; revisión de equidad por distrito.	Criterios de aceptación definidos antes de entrenar.
5. Despliegue	Artefactos estáticos (`docs/data`) y API opcional; umbrales en cliente.	Plan de reversión: versión anterior del manifest.
6. Monitorización	Drift de features y de scores, calidad de datos, tasa de aprobación del técnico, reentrenamiento por active learning.	Alertas y revisión periódica (mensual).

3 Datos y features

Cada celda H3 (res. 9, ≈ 0,1 km^2) recibe las variables siguientes (contrato de datos v1):

Variable	Descripción
`green_m2_per_capita`	m^2 de verde público accesible por habitante (referencia OMS 9–15).
`dist_green_m`	Distancia al espacio verde de ≥ 0,5 ha más cercano (regla de 300 m).
`canopy_pct` , `ndvi_mean` , `ndvi_trend`	Cobertura vegetal, NDVI medio del último año y pendiente Theil-Sen.
`lst_c`	Temperatura superficial media de verano (calor).
`vulnerability`	Índice de vulnerabilidad socioeconómica (0–1).
`population` , `floating_population`	Residentes (INE) y población flotante diurna (Smart Steps).

NOTA

En la demo, NDVI, LST, INE y Smart Steps son **sintéticos** (generador determinista con semilla) y sólo la geometría procede de OSM. Las métricas siguientes miden por tanto la capacidad del sistema de recuperar una estructura *construida*, no el rendimiento sobre la realidad.

4 Modelado

4.1 Segmentación de vegetación

Baseline: umbral de NDVI (p. ej. > 0,3–0,4) combinado con máscaras OSM. **Mejora**: U-Net ligera sobre Sentinel-2 (interfaz opcional `dl`/PyTorch). **Producción**: embeddings de foundation models (Prithvi-EO-2.0, Clay) con una cabeza ligera ajustada con pocas etiquetas, para tratar los parches pequeños donde fallan U-Net/ResNet (doc. 01).

4.2 Series temporales

Técnica	Uso
STL	Descompone NDVI/LST mensual en tendencia, estacionalidad y residuo (robusto a huecos).
Theil-Sen	Pendiente robusta de la tendencia (`ndvi_trend` , unidades/año); insensible a valores atípicos.
Holt-Winters	Previsión a 12 meses del NDVI con intervalos (`ndvi_forecast` , `_lo` , `_hi`).
Detección de anomalías	Residuos STL fuera de ±k·MAD o caída sostenida de tendencia → `anomaly = true` .

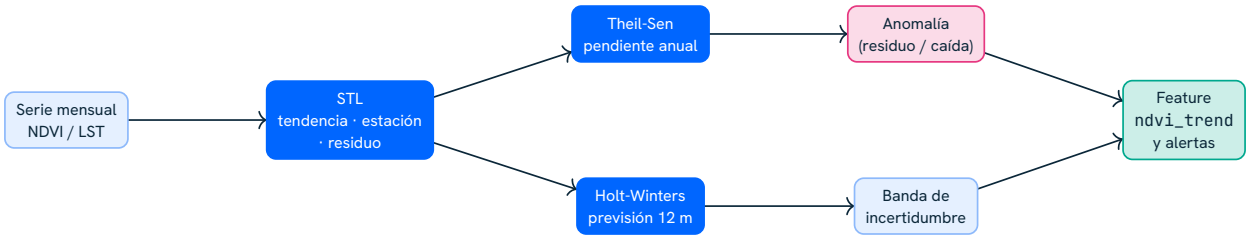


Figura 2: Pipeline de series temporales por celda.

4.3 Modelo de déficit

1. **Índice compuesto** (conocimiento experto): combinación ponderada normalizada de m^2/hab inverso, distancia al verde, calor, vulnerabilidad y demanda efectiva (residentes + flotantes). Sirve como *weak supervision*: genera etiquetas ruidosas (déficit alto/bajo).
2. **LightGBM** entrenado con esas etiquetas débiles más las decisiones humanas disponibles; aprende interacciones no lineales y las generaliza a celdas con datos parciales.
3. **Calibración** de probabilidades (isotónica/Platt) para que el score 0–1 sea interpretable y los umbrales tengan sentido estable.
4. **Incertidumbre** (`uncertainty`): desviación entre modelos del conjunto y/o entre semillas.
5. **SHAP**: contribuciones por celda (`top_factors` , 3–5 variables) que se muestran al técnico.

> **ATENCIÓN**
>
> La **weak supervision** introduce un riesgo de circularidad: el modelo puede aprender el índice con el que se etiquetó. Mitigación: validar con etiquetas humanas (decisiones del técnico) y reportar la discordancia modelo–índice.

4.4 Ranking multicriterio de propuestas

Candidatas: solares vacantes, aparcamientos, interbloques, chaflanes y calles pacificables en celdas con déficit alto. La prioridad combina (pesos configurables, inspirado en F-AHP):

$$\text{prioridad} = w_1 \cdot \text{población servida} + w_2 \cdot \text{reducción de calor} + w_3 \cdot \text{déficit de la celda} - w_4 \cdot \text{coste}$$

Cada propuesta lleva `rationale` en español (por qué se propone), `served_population`, `est_cost_eur`, `est_cooling_c` y `co2_kg_year`. Estas dos últimas son ESTIMACIÓN basadas en coeficientes de la literatura, no mediciones.

5 Métricas y resultados

Métrica	Valor	Interpretación
AUC (déficit crítico)	0,992	Capacidad de ordenar celdas críticas frente a no críticas.
F1 en el umbral crítico	0,641	Equilibrio precisión/recall con umbral por defecto 0,70.
MAE de previsión NDVI	0,024	Error medio absoluto de Holt-Winters a 12 meses (retención).
Celdas analizadas	763	Madrid central, H3 res. 9.
Propuestas generadas	454	Candidatas con prioridad ≥ `min_proposal_priority` .

NOTA

Métricas leídas de `docs/data/manifest.json` (modelo **deficit-lgbm-0.1.0**, generado el 2026-10-25T02:57:26+02:00, esquema v1.0.0). Ámbito: bbox −3.75, 40.38, −3.64, 40.46, periodo 2019-01 – 2026-09. Datos con fuentes sintéticas: no extrapolar a la realidad.

6 Gestión de calidad, monitorización y active learning

Ámbito	Indicador	Acción
Calidad de datos	Completitud, rango, frescura de cada `DataSource` .	Bloquear publicación si falla el esquema.
Drift de datos	PSI/KS de las features frente al entrenamiento.	Alerta y reentrenamiento programado.
Drift de modelo	Distribución del score y estabilidad de rankings.	Revisión humana del cambio de versión.
Equidad	Error y tasa de propuestas por distrito y vulnerabilidad.	Recalibrar o ajustar pesos.
Uso humano	Tasa de aprobación, rechazo y ajuste por tipo de propuesta.	Priorizar celdas con desacuerdo para etiquetar.

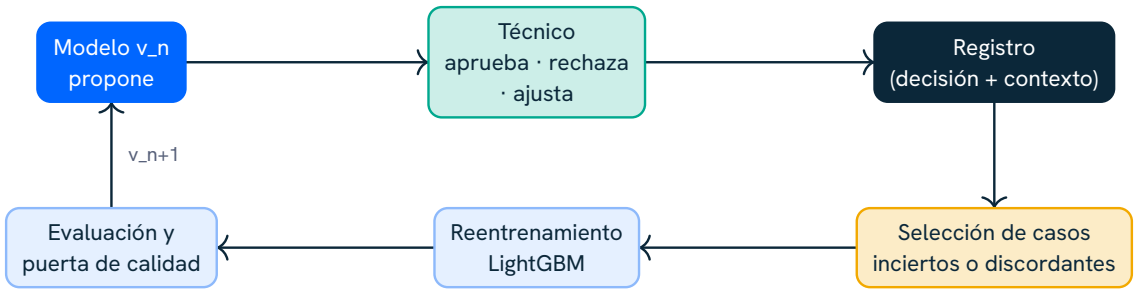


Figura 3: Bucle de active learning con las decisiones del técnico.

DECISIÓN

Un modelo nuevo sólo se publica si supera la puerta de calidad (métricas no peores que la versión anterior y sin deterioro de equidad) y un técnico lo revisa.

HISTORIAL DE VERSIONES

Versión	Fecha	Cambios
0.1	25-10-2026	Esquema del plan: modelos y fases.
0.2	25-10-2026	CRISP-ML(Q) por fase, series temporales, modelo de déficit, ranking y plantilla de métricas ligada a manifest.json.